Resumo executivo – Evolução da plataforma de Pedidos e Catálogo

Situação

A plataforma atende só o web nacional. Em 90 dias precisa atender app, parceiros de marketplace e um segundo país, com 10x de volume, 99,9 % de disponibilidade e p95 de 500 ms na criação de pedido. Hoje ela tem quatro falhas que pioram com escala: pedido duplicado em retry, evento publicado fora da transação, N+1 síncrono no Catálogo e ausência de snapshot de preço. Não há API versionada para parceiros nem separação de dados por país.

Recomendação

Evoluir o sistema atual em três ondas, sem reescrita e sem janela de indisponibilidade:

1. **30 dias – parar de errar.** Criação de pedido idempotente (`Idempotency-Key`), snapshot de preço e descrição, evento gravado na mesma transação (outbox). Contrato atual preservado; `/v2` preparado. Observabilidade e SLOs ativos.
2. **60 dias – escalar e abrir.** Catálogo consultado em lote com cache e circuit breaker; broker alimentado pela outbox; gateway com OAuth2 e quotas; app em produção no `/v2`; webhooks com parceiros piloto.
3. **90 dias – expandir.** Segundo país: todo pedido já grava o país; se a lei exigir que dados pessoais fiquem no país, sobe só uma célula mínima (API de Pedidos + banco na região); parceiros em produção; anúncio de depreciação do `/v1` com prazo mínimo de 6 meses.

A decisão mais crítica (idempotência + contrato versionado + outbox) está provada na fatia executável do repositório: chamadas repetidas com a mesma chave não duplicam pedido e o consumidor atual do `/v1` continua funcionando, com testes automáticos no pipeline.

Principais decisões (ADRs)

Decisão	Por quê
Idempotency-Key persistida com o pedido	Retry seguro; base para todos os mecanismos de resiliência
Outbox transacional	Evento existe se e só se o pedido foi gravado
Consulta em lote + snapshot	Latência estável e auditoria de preço
Versão na URL, v1 e v2 lado a lado	Nenhum consumidor atual quebra
Residência: coluna de país; célula mínima só se a lei exigir	Não gasta antes de a regra ser conhecida; broker e notificador não são duplicados
Webhooks assinados	Notificação a parceiros sem expor infraestrutura
OAuth2 + quotas no gateway	Um parceiro não derruba os outros

Investimento

Fase	Sem IA	Com IA no desenvolvimento	Infraestrutura
30 dias	~116 pessoa-dia · ≈ R$ 93,2 mil	~93 pessoa-dia · ≈ R$ 79,2 mil (−15 %)	A cotar após medir o tráfego

Fase	Sem IA	Com IA no desenvolvimento	Infraestrutura
60 e 90 dias	~275 pessoa-dia · ≈ R$ 214,6 mil	~218 pessoa-dia · ≈ R$ 178,4 mil (−17 %)	A cotar após definir país e provedor

Custo = salário CLT × 1,66 (encargos e provisões), sem benefícios; o cenário com IA inclui as licenças. O ganho com IA (~20 % de esforço) vem de estudos publicados e será medido nas semanas 1 e 2; o prazo não muda, porque é ditado pelo rollout seguro. O preço da proposta acrescenta tributos e margem, definidos pela área comercial.

Riscos principais

- **Tráfego real desconhecido.** Dimensionamento por premissa (20 → 200 criações/s). Medir na semana 1.
- **Regra de residência do segundo país não definida.** Decide entre coluna de país (custo zero) e célula mínima na região. Parecer até o dia 30.
- **Consumidores atuais de eventos não mapeados.** Pode alongar o período de dupla publicação.
- **Adoção da chave pelo web.** Sem ela, o `/v1` ainda pode duplicar.

Decisões que precisam de validação do cliente

1. Baseline de tráfego e contrato v1 real.
2. País, regra de residência e parecer jurídico (LGPD e lei local).
3. Preço vale no momento do pedido; defasagem de até 60 s no cache é aceitável; com o Catálogo fora, vender pelo último preço conhecido por até 15 min (ou recusar o pedido).
4. Retenção da chave de idempotência em 24 h.
5. Provedor de nuvem, broker e gateway (critérios prontos; escolha na semana 1).
6. Salário de SRE/DevOps (premissa), benefícios, tributos e margem da proposta.
7. Piloto do assistente de IA para o atendimento após os 90 dias.